Laporan: Akurasi Ekstraksi dan Performa Scraper Berita

- **Tanggal:** 2 November 2026
- **Lingkup:** `scraper/` (Bun + Chrome headless) dan `go-scraper/` (Go tanpa browser)
- **Rincian:** ADR-0003 · ADR-0004 (ditolak) · ADR-0005 · benchmark akurasi · benchmark driver

Ringkasan

- **Akurasi isi berita 100% recall dan 99,9% precision** pada 24 artikel dari 8 sumber. Judul, tanggal terbit, dan penulis 100% cocok dengan yang tampil di halaman asli.
- **Browser tidak menentukan akurasi; aturan ekstraksi yang menentukan.**
  - agent-browser, CDP Bun, dan Playwright menghasilkan isi identik.
  - Port aturan yang sama ke Go **tanpa browser** menghasilkan teks isi identik persis di 24/24 artikel.
  - Efek tanpa browser hanya terlihat di daftar gambar 3 artikel: thumbnail berita terkait, placeholder lazy-load, dan host CDN gambar utama.
- **go-trafilatura (dipakai sistem produksi Go) kurang bersih:** precision 88,9%, dengan 135 paragraf bukan berita. Tanggal terbit benar hanya 12/18, dan gambar di dalam isi 2/31.
- **Go tanpa browser paling ringan:** ±100–120 MB, dibanding ±1,8–1,9 GB untuk Chrome. Waktunya setara Playwright dan ±3× lebih cepat dari CDP Bun dalam putaran yang sama.
- **agent-browser paling lambat** (±26 dtk per artikel), karena menunggu semua iklan selesai dimuat.
- **Ekstraksi dengan AI agent (Hermes) ditolak** (bagian 4).

1. Akurasi

Metode

- Hasil scraper dibandingkan dengan **halaman aslinya**, bukan dengan hasil scraper lain.
- Pembanding diambil dari HTML lewat request HTTP biasa, memakai selector yang dipilih manual per situs.
- Sampelnya 24 artikel, 3 terbaru per sumber, dengan URL yang sama untuk semua implementasi dan semua putaran.
- Definisi:
  - **Recall:** bagian isi berita di halaman yang ikut terambil.
  - **Precision:** bagian teks hasil scraper yang benar-benar isi berita; sisanya iklan, footer, atau tautan.

Implementasi yang diukur:

Implementasi	Cara membuka halaman	Aturan ekstraksi
Bun + browser (agent-browser, CDP Bun, Playwright)	Chrome headless	`extract-article.js`, dijalankan di halaman
Go (rules)	HTTP biasa, tanpa browser	Port 1:1 `extract-article.js` dan `scrape-article.js` ke Go
Go (trafilatura)	HTTP biasa, tanpa browser	go-trafilatura v1.12.2, seperti sistem produksi Go

Ketiganya memakai aturan pagination yang sama. Tidak ada yang memeriksa robots.txt.

Hasil (24 artikel, semuanya berhasil dibaca ketiga implementasi)

	Bun + browser	Go (rules)	Go (trafilatura)	Penyebab hasil Go (trafilatura) berbeda
Recall	100%	100%	99,1%	Sebagian isi sindonews hilang. Di sindonews isinya dipisah ` ` tanpa `<p>`, dan satu paragraf yang diawali subjudul ("3. Ada Kelompok Ekstremis...") dibuang. Penyebab persis di trafilatura belum diperiksa
Precision	99,9%	99,9%	**88,9%**	Teks bukan berita ikut terambil (baris di bawah)
Paragraf hilang	0	0	1	Paragraf sindonews di atas
Paragraf bukan berita	0	0	**135**	Filter trafilatura generik, tidak mengenal label situs berita Indonesia: `ADVERTISEMENT`, `SCROLL TO CONTINUE`, "Baca juga", `Pewarta:/Editor:`, larangan AI antaranews, inisial `(isa/isa)`, `[Gambas:…]`, dan kredit foto. Di artikel multi-halaman, sampah ini berulang di setiap halaman
Judul	24/24	24/24	21/24	Ketiga artikel okezone: judul diambil dari `<title>` beserta akhiran `: Okezone …`. Rules mengutamakan JSON-LD `headline`
Tanggal terbit	18/18	18/18	**12/18**	Keenam artikel cnnindonesia dan detik: jam benar, tetapi zona WIB ditulis `Z` (UTC), sehingga meleset 7 jam. go-htmldate membaca jam tanpa zona waktu lalu menganggapnya UTC (string asal yang dibacanya belum diperiksa). Rules mengambil `datePublished` JSON-LD atau `article:published_time` apa adanya, lengkap dengan zonanya. Tanpa opsi `ExtractTime`, hasilnya 0/18 karena hanya tanggal yang diambil (`T00:00:00Z`)
Penulis	12/12	12/12	12/12	Sama
Gambar di dalam isi	28/31	28/31	**2/31**	viva (2/27): lazy-load `data-original` tidak dikenali; go-trafilatura hanya membaca `src` / `data-src*` berekstensi gambar. cnnindonesia (0/3): gambar ber-`src` biasa pun tidak ikut; dugaan, blok gambar di luar paragraf dibuang trafilatura (belum diperiksa). okezone (0/1): belum diperiksa

Kolom "Bun + browser" diukur dengan CDP Bun. Dalam putaran performa pada URL yang sama, isi dan judul dari agent-browser dan Playwright identik dengan CDP Bun di 22/22 artikel yang berhasil dibuka ketiganya.

- **Tanggal dan penulis:** hanya dinilai di situs yang menampilkannya di halaman (6 situs untuk tanggal, 4 situs untuk penulis).
- **Metadata lain:** deskripsi dan gambar utama terisi 24/24 di semua implementasi. Seksi hanya 9/24 karena banyak situs tidak menyediakannya.

Hasil per sumber: recall / precision (%)

Sumber	Bun + browser	Go (rules)	Go (trafilatura)	Penyebab hasil Go (trafilatura) berbeda
antaranews	100 / 100	100 / 100	100 / 80	Footer redaksi (`Pewarta:` / `Editor:` , `Copyright © ANTARA`), larangan AI, "Baca juga", dan embed tweet ikut
cnnindonesia	100 / 100	100 / 100	100 / 96	`ADVERTISEMENT` , `SCROLL TO CONTINUE WITH CONTENT` , dan dateline `Jakarta, CNN Indonesia --` ikut
detik	100 / 100	100 / 100	100 / 96	`SCROLL TO CONTINUE WITH CONTENT` , inisial redaksi `(isa/isa)` , dan dateline ikut
liputan6	100 / 100	100 / 100	100 / 96	`Advertisement` dan ajakan promosi kanal ikut
sindonews (2–3 halaman)	100 / 99	100 / 99	93 / 64	Baris tanggal, "loading...", dan tombol ukuran huruf "A A A" ikut, berulang di setiap halaman; satu paragraf berawalan subjudul hilang
cnbcindonesia	100 / 100	100 / 100	100 / 97	Inisial redaksi dan placeholder video `[Gambas:Video CNBC]` ikut
okezone (2–4 halaman)	100 / 100	100 / 100	100 / 98	Kredit redaksi dalam kurung ikut
viva (2–3 halaman)	100 / 100	100 / 100	100 / 84	Kredit foto (`REUTERS/…` , `Dok. …`) dan judul berita terkait ikut, berulang di setiap halaman

Efek tanpa browser

CDP Bun dan Go (rules) dijalankan berurutan pada ke-24 artikel, lalu hasilnya dibandingkan per artikel.

Aspek	Hasil
Teks isi	**Identik persis 24/24**: jumlah kata, jumlah paragraf, dan setiap karakter sama
Judul, tanggal terbit, penulis, deskripsi, tag	Identik 24/24
Skor akurasi (recall, precision, gambar di dalam isi)	Identik 24/24
Daftar gambar	Sama di 21/24; berbeda di 3 artikel (rincian di bawah)

Perbedaan di daftar gambar:

Artikel	Perbedaan	Penyebab
liputan6 (1 artikel)	Go mengambil 5 thumbnail berita terkait (200×113) yang tidak ada di browser: 23 vs 18 gambar	Dugaan: di browser, JavaScript lazy-load mengganti atau menghapus elemen thumbnail itu
detik (1 artikel)	Go mengambil placeholder lazy-load `loading.gif` sebagai gambar	Dugaan: di browser, JavaScript mengganti placeholder dengan gambar asli yang sudah ada di daftar
antaranews (1 artikel)	Gambar utama sama, tetapi host CDN-nya beda: `img.antaranews.com` (HTML server) vs `cdn.antaranews.com` (browser)	Nilai di HTML server diubah setelah halaman dimuat

- **Satu temuan tidak terulang.** Di putaran benchmark, ketiga driver browser menemukan 11 gambar di satu artikel cnnindonesia, sedangkan Go menemukan 2. Saat diulang, browser juga hanya menemukan 2,

jadi penyebabnya tidak bisa dipastikan.

- **Batasan yang tidak muncul di 8 sumber ini, tetapi berlaku untuk sumber lain:**
  - isi atau link pagination yang baru muncul lewat JavaScript tidak terbaca;
  - elemen yang disembunyikan lewat CSS tetap terbaca.

Aturan ekstraksi yang dipakai (`extract-article.js`)

Ekstraktor tidak bergantung pada daftar selector per situs:

1. **Daftar selector umum** situs berita, yang hasilnya diperiksa dengan **skor kepadatan paragraf** (mirip Readability). Situs dengan struktur yang belum dikenal tetap tertangani lewat skor ini.
2. **Filter elemen bukan berita** (iklan, "baca juga", share, penulis/tanggal, keterangan foto) dan **filter baris label** (`ADVERTISEMENT`, `Pewarta:/Editor:`, ajakan follow, placeholder video, inisial redaksi).
3. Isi yang tidak dibungkus `<p>` (sindonews) diambil per baris.

Sebelum aturan ini, okezone dan viva menghasilkan isi kosong, dan precision sindonews 76%. Setiap perubahan aturan wajib diterapkan juga di port Go, lalu diukur ulang dengan `bun run bench:accuracy --urls <hasil sebelumnya>`.

2. Performa

Hasil (16 artikel yang berhasil dibuka kelima implementasi, tanpa pembukaan pertama)

Implementasi	Median / artikel	p95	Cold start	Peak memory	Berhasil
agent-browser (default saat ini)	25,8 dtk	53,7 dtk	29,9 dtk	1,9 GB (Chrome)	22/24
CDP Bun	3,4 dtk	24,7 dtk	12,7 dtk	1,9 GB (Chrome)	23/24
Playwright	3,8 dtk	17,4 dtk	5,1 dtk	1,8 GB (Chrome)	23/24
Go (rules)	3,1 dtk	11,5 dtk	3,2 dtk	**101 MB** (proses Go)	21/24
Go (trafilatura)	1,9 dtk	9,7 dtk	2,0 dtk	119 MB (proses Go)	22/24

Median rasio waktu per artikel terhadap Go (rules), pada URL yang sama:

- agent-browser 8,7×
- CDP Bun 3,0×
- Playwright 1,1×
- Go (trafilatura) 0,85×

Batasan pengukuran:

- **Jaringan tidak stabil saat pengukuran.** Kelima implementasi mengalami timeout di okezone, detik, liputan6, dan cnbcindonesia. Di putaran lain saat jaringan normal, median CDP Bun 0,6 dtk dan Playwright 0,3 dtk (benchmark driver).
- Angka absolutnya berubah-ubah antar putaran. Yang konsisten: agent-browser selalu paling lambat, dan Go selalu lebih cepat dari driver browser. Urutan CDP Bun dan Playwright berganti antar putaran. Urutan implementasi digilir per URL supaya cache CDN tidak menguntungkan satu implementasi.
- **Cakupan memori tidak sama.** Untuk Go diukur seluruh prosesnya, untuk browser hanya pohon proses Chrome (proses Bun tidak ikut dihitung).

Penyebab selisih kecepatan

- `agent-browser open` menunggu event `load`, yaitu sampai semua iklan selesai dimuat; di situs penuh iklan waktunya bisa ±20 dtk.

- CDP Bun dan Playwright berhenti saat `DOMContentLoaded`, ketika isi berita sudah ada di halaman.
- Go hanya mengunduh HTML-nya, tanpa menjalankan JavaScript, gambar, atau iklan.

3. Perbandingan implementasi

	agent-browser	Playwright	CDP Bun	Go (rules)
Akurasi	Setara	Setara	Setara	Setara
Kecepatan	Lambat di situs penuh iklan	Cepat	Cepat	Cepat
Memori	±1,9 GB	±1,8 GB	±1,9 GB	±0,1 GB
Butuh Chrome di server	Ya	Ya	Ya	Tidak
Isi yang dirender JavaScript	Terbaca	Terbaca	Terbaca	Tidak terbaca; di 8 sumber ini hanya berdampak pada daftar gambar 3 artikel
Dependency	Binary npm global (butuh Node.js/npm di server)	`playwright-core`	Tidak ada	`x/net/html`, `cascadia`
Pemulihan crash Chrome	Belum ada	Otomatis	Otomatis	Tidak relevan
Perawatan	Pembungkus CLI	Pembungkus tipis	Klien CDP dan peluncur Chrome	Aturan ekstraksi dirawat di dua bahasa

4. Evaluasi AI agent (Hermes Agent): ditolak

Dikaji apakah membaca isi artikel lewat AI agent lebih andal daripada ekstraktor deterministik. Agent yang diuji adalah Hermes Agent dengan Claude Sonnet 5: membuka halaman dengan browser, lalu menyalin isi berita sesuai prompt. Uji cobanya 1 artikel detik dan 1 artikel liputan6 per backend, dinilai dengan alat akurasi yang sama.

Cara	detik	liputan6	Waktu / artikel	Biaya / artikel
Scraper deterministik (CDP Bun)	100 / 100	100 / 100	0,2–2,6 dtk	$0
Hermes + Browser Use (bawaan Hermes)	100 / 100	100 / 100	54–55 dtk	$0,043–0,048
Hermes + agent-browser 0.26.0	gagal (timeout)	100 / 100	40 dtk	$0,051

Recall / precision dalam persen.

Ditolak (ADR-0004), karena:

- **Akurasi tidak bertambah.** Ekstraktor deterministik sudah 100% / 99,9% pada 8 sumber.
- **Selector cukup ditentukan saat setup** dan diverifikasi dengan benchmark akurasi; tidak perlu AI.
- **Mahal dan lambat:** ±$45–50 per 1.000 artikel (perkiraan) dan ±25–250× lebih lambat, tanpa imbalan akurasi.
- **Risiko keamanan:** backend yang andal (Browser Use) butuh akses shell untuk agent sambil membaca halaman tak tepercaya.
- **Tidak deterministik:** risiko parafrase atau halusinasi teks.
- **Izin penerbit:** pemrosesan isi berita oleh AI dilarang sebagian penerbit (mis. antaranews tanpa izin tertulis).

5. Usulan

- **Untuk 8 sumber ini, browser tidak dibutuhkan.**
  - HTML server sudah memuat isi lengkap.
  - Aturan ekstraksi yang sama memberi hasil identik dengan atau tanpa browser.
  - Tanpa browser, memori turun dari ±1,9 GB ke ±0,1 GB.
- **Sistem produksi Go diusulkan memakai port aturan ini** (`go-scraper/internal/infrastructure/extract/rules`) sebagai pengganti go-trafilatura. Dampaknya:
  - precision naik dari 88,9% ke 99,9%;
  - tanggal terbit naik dari 12/18 ke 18/18;
  - gambar di dalam isi naik dari 2/31 ke 28/31.
- **Browser tetap disiapkan sebagai jalur cadangan** untuk sumber yang isinya hanya muncul lewat JavaScript. Jika jalur browser dipertahankan, Playwright atau CDP Bun dipakai, bukan agent-browser.
- Rincian dan pertanyaan terbuka ada di ADR-0005.

6. Risiko dan batasan

- **Izin penerbit:** footer antaranews melarang pengindeksan otomatis untuk AI tanpa izin tertulis, dan robots.txt tempo memasang `ai-train=no`. Pemakaian produksi perlu dipastikan izinnya.
- **Aturan di dua bahasa:** setiap perubahan `extract-article.js` harus diterapkan juga di port Go dan diukur ulang dengan alat yang sama.
- **Sumber terblokir:** tempo, republika, dan tribunnews memblokir Chrome headless dan tidak diukur.
- **Sampel kecil:** 24 artikel dari 8 sumber pada satu hari.

Sumber

Repo: github.com/adehikmatfr/news-scrap

Dokumen / kode	Isi
ADR-0003: driver browser	Pilihan driver lewat `BROWSER_DRIVER`, spike Windows/Linux, sandbox
ADR-0004: Hermes Agent (ditolak)	Data spike Hermes dan alasan penolakan
ADR-0005: komparasi scraper Go tanpa browser	Port Go, hasil per sumber, usulan, dan pertanyaan terbuka
Benchmark akurasi ekstraksi	Data per artikel dan per sumber, sebelum dan sesudah perbaikan ekstraktor
Benchmark driver browser	Performa ketiga driver browser saat jaringan normal
`extract-article.js`	Aturan ekstraksi yang dipakai ketiga driver browser
`agent-browser-cli.js` · `cdp-driver.js` · `playwright-driver.js`	Implementasi ketiga driver browser
`go-scraper/`	Scraper Go tanpa browser (clean architecture)
`rules.go` · `scrape_article.go`	Port Go dari `extract-article.js` dan `scrape-article.js`
`compare-with-source.js`	Alat ukur akurasi (`bun run bench:accuracy`)
`compare-drivers.js`	Alat ukur performa (`bun run bench`)